

## Exercicio 6 - Redes Neurais Artificiais

Andre Costa Werneck

16/05/2022

# 1 ELM

## 1.1 BASE BREAST CANCER

Para a base do Breast Cancer, seguem as acuracias com:

$p = 5$

acuracia treino = 0.818609406952965 +- 0.0519600261756431

acuracia teste = 0.92822966507177

$p = 10$

acuracia treino = 0.877300613496933 +- 0.026247413259615

acuracia teste = 0.923444976076555

$p = 30$

acuracia treino = 0.946625766871166 +- 0.0101036830150759

acuracia teste = 0.942583732057416

$p = 50$

acuracia treino = 0.96002044989775 +- 0.00598882362225615

acuracia teste = 0.961722488038278

$p = 100$

acuracia treino = 0.980163599182004 +- 0.00393081764120972

acuracia teste = 0.952153110047847

$p = 300$

acuracia treino = 1 +- 0

acuracia teste = 0.803827751196172

Para começar a análise, vale ressaltar que para cada treinamento da rede, com cada número diferente de neurônios, foi feito um loop for que repetiu o treinamento e pegou os valores médios da acurácia, dos pesos e de  $Z$ , como pedido.

Dessa forma, observou-se, claramente, que para o conjunto de treinamento, a convergência do modelo aumenta a medida que o número de neurônios também cresce. Entretanto, a acurácia de teste parece ser máxima com o valor de  $p=30$  ou  $p=50$ , nesse caso. Foi muito interessante notar, ademais, que se aumentarmos

muito o numero de neuronios, a acuracia do conjunto de teste cai consideravelmente, mesmo que a acuracia do conjunto de treino permaneca maxima (em 100%). Isso e um sinal claro de perda de capacidade de generalizacao do modelo, ou seja, e um forte indicio de overfitting. Dessa forma, foi valido observar que nem sempre a maxima acuracia de treino representa a melhor solucao para o problema, ilustrando ponto que ja haviamos aprendido nas aulas da disciplina.

Vale ressaltar que um treinamento com a mesma base de dados foi realizado com um Perceptron simples no exercicio anterior. No caso do perceptron, houve boa convergencia com um numero de epocas a partir de 100, com acuracia chegando a 97,6%. Comparando os dois modelos vale dizer que foi observada uma maior rapidez na ELM para uma acuracia muito semelhante (com  $p=30$  e 50). Dessa forma, creio que fica evidente a melhora gracas a linearizacao do modelo advinda da camada escondida da ELM, modelo que pareceu apresentar, para esse, problema, menor custo computacional.

## 1.2 Statlog (Heart)

Para a base da Statlog, seguem as acuracias com:

$p = 5$

acuracia treino = 0.73042328042328 +- 0.0249044326383322

acuracia teste = 0.716049382716049

$p = 10$

acuracia treino = 0.858465608465608 +- 0.0194119523477172

acuracia teste = 0.802469135802469

$p = 30$

acuracia treino = 0.886243386243386 +- 0.00697297912868221

acuracia teste = 0.765432098765432

$p = 50$

acuracia treino = 0.905820105820106 +- 0.0086855310229431

acuracia teste = 0.777777777777778

$p = 100$

acuracia treino = 0.953703703703704 +- 0.0109750188799435

acuracia teste = 0.703703703703704

$p = 300$

```
acuracia treino = 1 +- 0
acuracia teste = 0.580246913580247
```

Observou-se que a mesma análise da base do breast cancer pode, também, ser feita para a base da Stalog. Vale apenas ressaltar que o modelo teve muito mais dificuldade de aprendizado para a presente base. Foi necessária uma normalização dos dados para ajudar na obtenção de uma solução melhor e, mesmo convergindo até 100% no treinamento, para os conjuntos de teste, a acurácia máxima não passou muito dos 85%. No que concerne overfitting e acurácias máximas, a análise é idêntica à da base do breast cancer.

## 2 Perceptron - Statlog(heart)

### Confusion Matrix and Statistics

```

      Reference
Prediction 0  1
      0 19 11
      1 14 37

      Accuracy : 0.6914
      95% CI : (0.5789, 0.7893)
No Information Rate : 0.5926
P-Value [Acc > NIR] : 0.04334

      Kappa : 0.3516

McNemar's Test P-Value : 0.68916

      Sensitivity : 0.5758
      Specificity : 0.7708
Pos Pred Value : 0.6333
Neg Pred Value : 0.7255
Prevalence : 0.4074
Detection Rate : 0.2346
Detection Prevalence : 0.3704
Balanced Accuracy : 0.6733

'Positive' Class : 0
```

Observou-se que, com o Perceptron, assim como na base do Breast Cancer, houve maior dificuldade de aprendizagem. A acurácia ficou um pouco menor e o treinamento foi muito mais custoso em termos de tempo e recursos computacionais. Dessa forma, se conclui que a camada intermediária que lineariza o problema realmente é efetiva em casos de problemas multivariados nos quais, apenas com um classificador linear, existe grande dificuldade de aprendizado.