

**Redes Neurais Artificiais**



**André Costa Werneck, Matrícula: 2017088140**

**LISTA 5**

**08/05/2022**



1) Base 2dnormals e:

- $P = 5$  neurônios





Acurácia = [1] 0.94

- $P = 20$





Acurácia = [1] 0.95

- $P = 50$



Acurácia = [1] 0.94

- $P = 100$




Acurácia = [1] 0.96


Conclusão para base 2dnormals

Foi observado no experimento feito acima, no qual se treinou uma base bidimensional normal com uma ELM com diferentes números de neurônios e 2 classes, diferentes resultados graças a variação do número de neurônios. Como o problema apresenta apenas 2 classes, um número de neurônio pequeno, como 5, apresentou uma curva de separação muito semelhante a uma reta e foi satisfatório, obtendo visualmente uma classificação justa e uma acurácia calculada de 94%, comprovando o escrito anteriormente. Ao se aumentar o número de neurônios, a gaussiana de separação foi alterando de formato e começou a buscar os pontos de fronteira com mais exatidão apresentando boa separação para  $p=20$  e 50 neurônios, mas já com um sinal de overfitting para  $p=100$ . Vale ressaltar, também, que para  $p=5$  a classificação obtida foi boa pois o problema era simples e bidimensional. Provavelmente, para problemas de classificação mais complexos, a separação não seria tão boa com um número baixo de neurônios.

## 2) Base XOR e:


- $P = 5$






Acurácia = [1] 0.93


- $P = 20$






Acurácia = [1] 0.99

- $P = 50$









Acurácia = [1] 1

- $P = 100$







Acurácia = [1] 1

### Conclusão para base XOR

Para a base XOR, o resultado do experimento teve conclusão semelhante ao experimento com a base 2dnormals. O problema XOR é um pouco mais complexo e, visualmente, apresentou sinais de overfitting mais cedo, me surpreendendo. Com  $p=20$ , já se observa uma curva que busca passagem muito próxima aos pontos de fronteira. Não é em vão que a acurácia saiu de 93% com  $p=5$  para 99% e 100% com os outros valores de  $p$ , representando, se somado às análises visuais das superfícies de separação, um sinal claro de overfitting. Dessa forma, para um problema de classificação XOR, um número de neurônios mais baixo, entre 5 e 20, pode ser a melhor solução.



### 3) Base Circle e:

- $P = 5$





Acurácia = [1] 0.92

- $P = 20$





Acurácia = [1] 0.98

- $P = 50$



Acurácia = [1] 1

- $P = 100$



Acurácia = [1] 1


### Conclusão para base Circle


Para a base Circle, a conclusão se difere das bases anteriores apenas no fato de que o

overfitting demorou um pouco mais para acontecer. Observa-se que a intenção é obter uma gaussiana radial, circular, de separação e classificação dos dados. Ela é obtida com uma certa clareza visual até  $p=50$  neurônios. Para  $p = 100$ , a superfície de classificação já não se parece mais com uma circunferência e isso é um sinal de overfitting, uma vez que ela passa exatamente pelos pontos fronteiros e ignora o erro inerente e saudável ao experimento.

#### 4) Base Spirals e:


- $p = 5$






Acurácia = [1] 0.74

- $p = 10$









Acurácia = [1] 0.97


- $p = 20$






Acurácia = [1] 1

- $p = 50$





Acurácia = [1] 1

### Conclusão para a base Spirals

Para a base Spirals, o experimento apresentou algumas diferenças relevantes. De primeira, para um  $p = 5$ , como pode ser observado acima, o modelo de ELM não conseguiu aprender muito bem e classificou apenas 74% das amostras corretamente. Entretanto, provando a enorme sensibilidade desse problema ao número de neurônios, observou-se uma convergência rápida e muita diferença de aprendizado para o teste com  $p=10$ , 20 e 50 neurônios. A acurácia saltou de 74% para 97% e 100%, respectivamente, e a superfície foi ficando mais com a cara de uma espiral, como deveria ser. Entretanto, semelhantemente ao problema da base Circles, com um número mais alto de neurônios, como 50, por exemplo, a gaussiana de separação vai perdendo a forma espiral e começa a apresentar sinais claros de overfitting. Dessa forma, conclui-se que essa base foi a que mais apresentou sensibilidade ao número de neurônios e foi a mais difícil de ser aprendida, uma vez que com um  $P$  baixo, o modelo não consegue apresentar uma solução apropriada.

## ANEXOS

O código para realização dos exercícios 1, 2, 3 e 4 se encontra devidamente documentado, através dos comentários, em anexo:

```
<<echo=FALSE,results=hide>>=
# gerando os dados de entrada
rm(list = ls())

library('mlbench')
library('corpcor')
library('caret')
library('plot3D')

cd0 <- mlbench.2dnormals(200)

cd1 <- mlbench.xor(100)

cd2 <- mlbench.circle(100)

cd3 <- mlbench.spirals(100,sd = 0.05)

# funcao ELM
treinaELM <- function(Xin, Yin, p){
  #pega as dimensoes

  N <- dim(Xin)[1]
  n <- dim(Xin)[2]

  # coloca 1 para termo de polarizacao

  Xaug <- cbind(Xin,1)
  #cria Z aleatoriamente
  Z <- replicate(p,runif((n+1),-0.5,0.5))

  # calcula H
  H <- tanh(Xaug %*% Z)

  #calcula pseudoinversa
  Hinv <- pseudoinverse(H)

  # calcula w
  W <- Hinv %*% Yin
```

```
return(list(W,H,Z))
```

```
}
```

```
# funcao para calcular saida da ELM
```

```
YELM <- function(Xin,Z,W){
```

```
  n <- dim(Xin)[2]
```

```
  Xaug <- cbind(Xin,1)
```

```
  H <- tanh(Xaug %*% Z)
```

```
  Yhat <- sign(H%*%W) # retorna -1,0 ou 1 de acordo com o sinal do numero calculado
```

```
  return(Yhat)
```

```
}
```

```
@
```

```
\begin{itemize}
```

```
\item Base "2dnormals"
```

```
\newline
```

```
<<echo=FALSE>>=
```

```
x <- as.matrix(cd3$x)
```

```
y <- as.matrix(cd3$classes)
```

```
class(y) <- "numeric"
```

```
y[y==2]<-(-1)
```

```
y[y==1]<- (1)
```

```
@
```

```
<<echo=false>>=
```

```
# selecionando aleatoriamente 70% das amostras de treino
```

```
separeTrainAndTest <- function(x,y,percTrain){
```

```
  xin <- x
```

```
yin <- y
```

```
indexTreino <- sample(dim(xin)[1])
```

```
Xtrain <- xin[indexTreino[1:(dim(xin)[1]*percTrain)],]
```

```
Ytrain <- as.matrix(yin[indexTreino[1:(dim(xin)[1]*percTrain)],])
```

```
Xtest <- xin[indexTreino[((dim(xin)[1]*percTrain)+1):dim(xin)[1]],]
```

```
Ytest <- as.matrix(yin[indexTreino[((dim(xin)[1]*percTrain)+1):dim(xin)[1]],])
```

```
return(list(Xtrain,Ytrain,Xtest,Ytest))
```

```
}
```

@

```
<<echo=false>>=
```

```
# training the model
```

```
p <- 50
```

```
model <- treinaELM(x,y,p)
```

```
W <- model[[1]]
```

```
H <- model[[2]]
```

```
Z <- model[[3]]
```

```
# calculando Yhat de treino
```

```
yhattrain <- YELM(x,Z,W)
```

```
acc <- y - yhattrain
```

```
acc <- length(acc[acc==0])/dim(y)[1]
```

```
accTrain <- as.numeric(confusionMatrix(factor(y),factor(yhattrain))$overall[1])
```

```
seqi <- seq(-2,2,0.1)
```

```
seqj <- seq(-2,2,0.1)
```

```
M <- matrix(0,nrow = length(seqi),ncol = length(seqj))
```

```

ci <- 0
for (i in seqi) {
  ci<-ci+1
  cj<-0
  for (j in seqj) {
    cj<-cj+1
    X<-as.matrix(cbind(i,j))
    M[ci,cj]<- YELM(X,Z,W)

  }

}

```

```

plot(x[,1],x[,2],col = 'red', xlim = c(-2,2), ylim = c(-2,2))
par(new=T)
#plot(Xblue[,1],Xblue[,2],col = 'blue', xlim = c(0,6), ylim = c(0,6),xlab = "",ylab = "")
#par(new=T)
@

```

```

\begin{figure}[!htb]
\begin{center}
<<echo=F,fig=TRUE>>=
plot(x[,1],x[,2],col = 'red', xlim = c(-2,2), ylim = c(-2,2))
par(new=T)
contour(seqi,seqj,M,xlim = c(-2,2),ylim = c(-2,2),xlab= "", ylab="")
@
\end{center}
\caption{Contorno da Superficie em 2D}
\label{Contorno da Superficie em 2D}
\end{figure}

```

```

\begin{figure}[!htb]
\begin{center}
<<echo=F,fig=TRUE>>=
persp3D(seqi,seqj,M,counter                                     =
T,theta=55,phi=30,r=40,d=0.1,expand=0.5,ltheta=90,lphi=180,shade=0.4,ticktype='de
tailed',nticks=5)
print(accTrain)

```

@

\end{center}

\caption{Contorno da Superfície em 3D}

\label{Contorno da Superfície em 3D}

\end{figure}

\end{itemize}

\end{document}